第十六周学习周报

Out: Feb 7, 2026
Due: Feb 13, 2026

电子科技大学
本科科研项目
脑机与深度学习 #16

Note: This article reflects the specific guidance and implementation ideas of policies and regulations over a certain period. Some content may be subject to timeliness issues, and certain conclusions drawn may lack concrete evidence, potentially leading to some logical inconsistencies. Therefore, this article is intended for internal discussion only.

1 本周学习内容一览

上周我们实现了 ATCNet+DANN，虽然取得了约 11% 的准确率提升，但也发现了 DANN 无条件域对齐的局限性。本周我深入研究了 Conditional Domain Adversarial Network（CDAN）方法，并成功实现了 ATCNet+CDAN。CDAN 通过引入类别条件信息，理论上应该能够实现更精细的域对齐。然而，实验结果却出乎意料——CDAN 相比 DANN 的提升非常有限。这促使我深入思考问题的根源，并为下一步的改进指明了方向。

2 为什么要改成 CDAN？

2.1 DANN 的不足之处

回顾上周的实验，DANN 虽然带来了性能提升，但存在一个根本性问题：**无条件的域对齐**。

DANN 的域判别器只接收特征向量作为输入，判断特征来自哪个域，而完全不考虑类别信息。这意味着什么呢？这意味着 DANN 会试图将所有特征（无论属于哪个类别）都对齐到一个统一的分布中。但在分类任务中，不同类别的特征本应该是分离的。这种无条件对齐可能会破坏类别间的判别性边界。

举个例子：假设我们有”左手运动想象”和”右手运动想象”两个类别。在源域（训练受试者）中，这两个类别的特征是分离的。但 DANN 的无条件对齐可能会将目标域

（测试受试者）的”左手”特征错误地对齐到源域的”右手”特征附近，导致分类错误。

2.2 CDAN 的理论优势

CDAN（Conditional Domain Adversarial Network）正是为了解决这个问题而提出的。它的核心思想是：**在域对齐时考虑类别信息**。

CDAN 的优势在于：

1. **类别条件化**：域判别器不仅接收特征，还接收类别预测信息，从而实现类别条件的域对齐
2. **保持判别性**：通过条件化，CDAN 可以在对齐域分布的同时保持类别间的判别性
3. **更精细的对齐**：CDAN 可以为每个类别分别进行域对齐，避免类别混淆

2.3 多线性条件的作用

CDAN 的关键技术是多线性条件化（multilinear conditioning）。具体来说，CDAN 将特征向量 f 和类别预测 p 通过外积（outer product）结合：

$$h = f \otimes p \tag{1}$$

这个外积操作生成了一个高维的条件特征表示，包含了特征和类别的联合信息。域判别器基于这个条件特征 h 进行判别，从而实现了类别条件的域对齐。

为什么要用外积而不是简单的拼接呢？外积能够捕捉特征和类别之间的交互信息，使得域判别器能够学习到”对于特定类别，特征应该如何对齐”这样的细粒度知识。

3 如何实现 CDAN？

3.1 架构改进

ATCNet+CDAN 的架构如图??所示（概念图）。

```
输入EEG信号
    ↓
ATCNet特征提取器
    ↓
特征向量 f
    ↓          ↓
标签分类器    类别预测 p
    ↓          ↓
类别预测     f   p（多线性条件化）
               ↓
          域判别器（带GRL）
               ↓
             域预测
```

图 1: ATCNet+CDAN 架构示意图

3.2 条件域判别器设计

与 DANN 相比，CDAN 的域判别器接收的输入维度更高。假设特征维度为 d_f，类别数为 C，则条件特征的维度为 $d_f \times C$。

条件域判别器的结构：

```
Input: h = f   p（维度: d_f × C）
    ↓
Linear(d_f × C, 1024) → ReLU → Dropout(0.5)
    ↓
Linear(1024, 512) → ReLU → Dropout(0.5)
    ↓
Linear(512, num_domains)
```

为了处理高维输入，我增加了隐藏层的维度，并使用了更深的网络结构。

3.3 与 DANN 的区别

CDAN 与 DANN 的主要区别总结如下：

表 1: DANN 与 CDAN 的对比

方面	DANN	CDAN
域判别器输入	特征 f	条件特征 $f \otimes p$
对齐方式	无条件全局对齐	类别条件对齐
类别信息	不考虑	显式考虑
参数量	较少	较多（高维输入）

4 CDAN 的实验结果

4.1 实验设置

为了公平对比，实验设置与 DANN 保持一致：

- 数据集：BCI Competition IV 2a
- 训练策略：LOSO 交叉验证
- 随机种子：seed 0-4（多 seed 验证）
- 超参数：与 DANN 相同

4.2 性能对比

表??展示了 ATCNet、DANN 和 CDAN 的性能对比。

表 2: 不同方法的性能对比

方法	准确率 (%)	Kappa	训练时间 (min)	参数量
ATCNet	57.68 ± 15.66	0.436 ± 0.209	66.93	113,732
ATCNet+DANN	68.67 ± 11.84	0.582 ± 0.158	95.46	187,701
ATCNet+CDAN	68.79 ± 11.34	0.584 ± 0.151	73.00	212,277
CDAN vs DANN	**+0.12%**	**+0.002**	**-22.46**	+24,576

4.3 CDAN 的混淆矩阵分析

图??展示了 CDAN 在 seed 0 上的平均混淆矩阵。与 ATCNet 相比，CDAN 在各类别上的分类性能都有所提升，对角线元素更加突出。

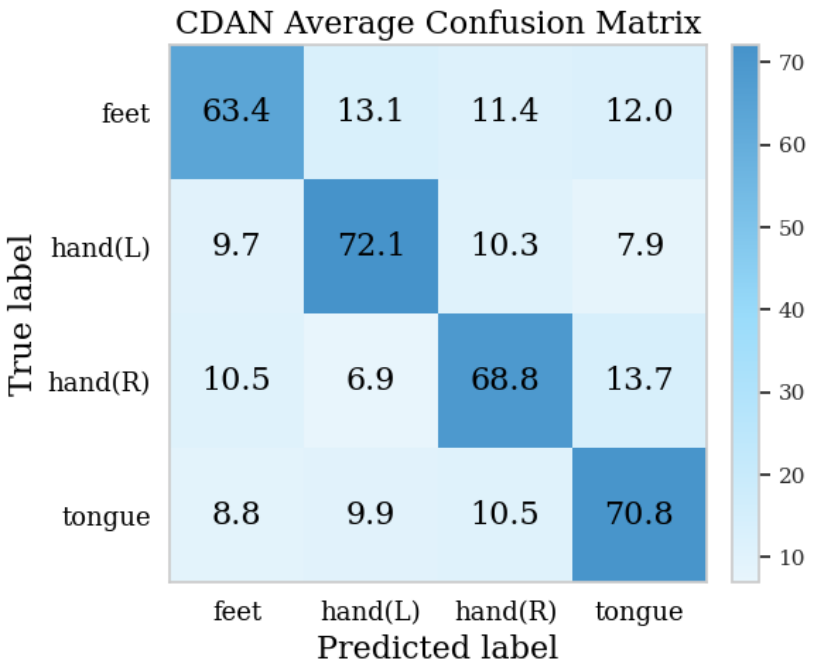

图 2: CDAN 在 seed 0 上的平均混淆矩阵（9 个受试者平均）

4.4 受试者级别的详细分析

表??展示了 CDAN 在各受试者上的表现。

表 3: CDAN 在各受试者上的表现对比

受试者	ATCNet	DANN	CDAN	CDAN vs DANN
Subject 1	71.18%	72.57%	72.22%	-0.35%
Subject 2	43.06%	47.92%	51.74%	+3.82%
Subject 3	77.08%	88.19%	89.24%	+1.05%
Subject 4	55.21%	67.36%	68.75%	+1.39%
Subject 5	26.74%	72.92%	63.89%	-9.03%
Subject 6	44.44%	52.43%	54.51%	+2.08%
Subject 7	69.79%	76.74%	79.51%	+2.77%
Subject 8	68.75%	76.39%	76.39%	0.00%
Subject 9	62.85%	63.54%	62.85%	-0.69%

5 为什么还要继续改进？

5.1 CDAN 的提升有限

从实验结果可以看出，CDAN 相比 DANN 的提升非常有限（仅 +0.12%）。这个结果让我感到意外，因为理论上 CDAN 应该比 DANN 更优。为什么会这样呢？

仔细分析受试者级别的结果，我发现了一些有趣的现象：

1. **有升有降：**CDAN 在某些受试者上表现更好（如 Subject 2, 7），但在另一些受试者上反而更差（如 Subject 5, 9）
2. **Subject 5 的性能下降：**CDAN 在 Subject 5 上的准确率从 72.92% 降到了 63.89%，下降了 9.03%。这是一个显著的退化。
3. **训练时间反而减少：**虽然 CDAN 的参数量更多，但训练时间反而比 DANN 少了 22 分钟。这可能是因为 CDAN 的收敛速度更快。

5.2 Subject 5 的性能对比

特别值得关注的是 Subject 5 的表现变化。图??展示了 ATCNet、DANN 和 CDAN 在 Subject 5 上的训练曲线对比。

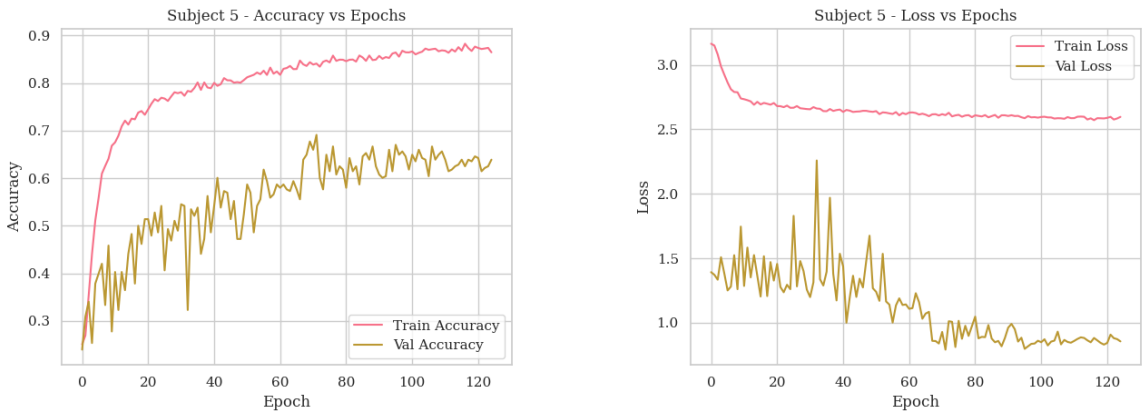

(a) CDAN 在 Subject 5 上的准确率曲线 **(b)** CDAN 在 Subject 5 上的损失曲线

图 3: CDAN 在 Subject 5 上的训练曲线。虽然相比 ATCNet 有显著提升（从 26.74% 到 63.89%），但相比 DANN 反而下降了 9.03%。

从图??可以看出，CDAN 在 Subject 5 上的验证准确率约为 64%，虽然远高于 ATCNet 的 27%，但低于 DANN 的 73%。这个现象很有趣：为什么理论上更优的 CDAN 反而在某些受试者上表现更差呢？

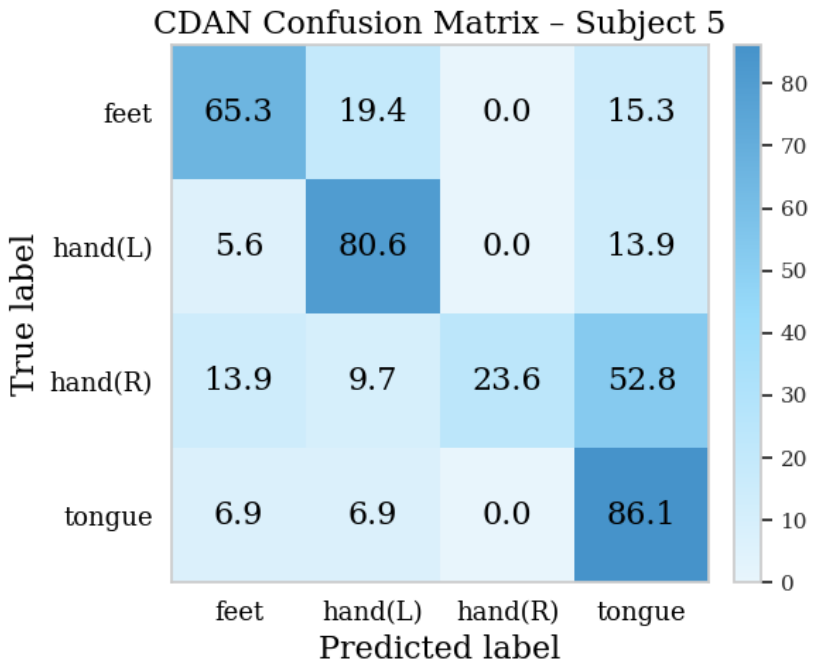

图 4: CDAN 在 Subject 5 上的混淆矩阵。相比 ATCNet 有明显改善，但仍存在一定的类别混淆。

5.3 存在的问题分析

CDAN 提升有限的原因可能有以下几点：

1. **多线性条件化的维度灾难：**外积操作使得条件特征的维度大幅增加（$d_f \times C$），这可能导致过拟合，特别是在数据量有限的 BCI 任务中。

2. **类别预测的不确定性：**CDAN 依赖于类别预测 p，但在训练初期，类别预测可能不准确。错误的类别信息可能会误导域对齐。

3. **对齐策略仍然过于简单：**虽然 CDAN 引入了类别条件，但它仍然是基于对抗训练的全局对齐策略。这种策略可能不适合 BCI 数据的特点。

4. **忽略了特征的局部结构：**CDAN 和 DANN 都是在特征空间进行全局对齐，没有考虑特征的局部结构和几何关系。

5.4 引出 FA-CDAN 的思路

基于以上分析，我开始思考：能否在 CDAN 的基础上引入特征对齐（Feature Alignment）机制？

特征对齐的思路是：不仅要对齐域分布，还要显式地对齐特征的统计特性（如均值、协方差）。这种对齐可以在特征空间的几何层面上减少域偏移，可能比单纯的对抗训练更有效。

下周我将尝试实现 FA-CDAN（Feature Alignment CDAN），结合对抗训练和特征对齐两种策略，期待能够取得更好的效果。

6 小结

本周成功实现了 ATCNet+CDAN，在 BCI2a 数据集上取得了与 DANN 相当的性能。CDAN 通过引入类别条件，在理论上应该比 DANN 更优，但实验结果显示提升有限（仅 0.12%）。

这个结果引发了我的思考：对抗训练虽然能让域判别器无法区分域，但这种对齐是隐式的、间接的。域判别器被”欺骗”了，但特征分布真的对齐了吗？还是只是变得更加混乱？如果我们采用更直接的方式——显式地最小化源域和目标域特征分布之间的距离，会不会效果更好？

特征对齐（Feature Alignment）的思路似乎很自然：直接计算并最小化特征的统计距离。但问题是，如何对齐才不会破坏类别结构？无条件的全局对齐会不会把不同类别的特征错误地拉到一起？这些疑问，需要在下周的实验中寻找答案。